

2025 SCPC : AI 챌린지

솔루션 발표

일상 사진을 풀어내는 멀티모달 AI 모델

Presenter.

배수현

Date.

2025.08.22.

DACON

Ricepunchb




Table of Contents

목차

01 문제 분석

- 문제 분석 및 정의

02 모델링 전략

- 파이프라인 설계

03 모델과 데이터셋 선정

- 모델 선정
- 데이터셋 선정

04 훈련 전략

- 데이터 증강
- 커리큘럼 러닝

05 최적화 및 성능 검증

- 최적화 기법
- 중간 성능 지표

06 마무리

- 결과물 확인
- 아쉬웠던 점

문제 분석 및 정의

일상 사진을 이해하고 관련 질문에 응답할 수 있는가



Question: What activity likely took place **before this moment?**

- A:** The final buzzer sounded, ending the game and starting celebrations.
- B:** The team lost a match and discussed strategies.
- C:** The team celebrated a victory with fans cheering.
- D:** The team was having a pre-game warm-up skate around the rink.



Question: What is the **cultural significance** of this dish?

- A:** It is traditionally served during Korean holidays and festivals
- B:** It is a popular Italian dish often served with pasta
- C:** It is a staple breakfast item in France, alongside croissants
- D:** It is a common fast food item in Japan, like ramen

필요 능력 분석

- 이미지에서 보여지는 시각적 정보를 올바르게 분석 할 수 있어야 함
- 시각적 정보 뿐만 아니라 그것을 토대로 추론 할 수 있는 능력도 필요
- 요구되는 능력
 - 이미지에서 디테일한 정보를 자연어로 추출
 - 주어진 정보를 토대로 추론할 수 있는 능력
 - 추론에 필요한 배경지식과 일반적 상식 보유
 - 한국 문화권에 대한 도메인 특화 지식

파이프라인 설계

어떻게 문제를 풀어야 하는가?

01

Scaling Law에 의해 작은 파라미터의 모델은 큰 모델보다 멀티 태스크 능력이 떨어짐



02

VLM 하나로 이미지 정보 추출, 추론 및 다중 선택지 QA를 하는것은 무리가 있음



03

강력한 싱글 태스크 모델 두 개를 end-to-end로 연결한 파이프라인 제안

파이프라인 설계

순차적으로 이미지 캡셔닝 후 그것을 읽고 질문에 답하는 전략

1

- VLM 모델이 이미지 캡셔닝을 수행
- 이미지에 있는 사물, 인물, 상황, 분위기 등을 자세하게 서술
 - 예시) The image shows a dolphin leaping out of the water, with its body outstretched and its fins outspread. The sky is clear and blue, and the sun is shining brightly. The dolphin's tail is visible, and it is surrounded by a ring of bubbles.



2

- 언어 모델이 이미지 캡셔닝과 질문, 선택지를 읽고 최종 답 선택
- 배경상식과 지식, 추론 능력을 활용하여 최종 답을 선택함

KOSMOS-2

강력한 이미지 캡셔닝 성능을 가진 VLM

KOSMOS-2: Grounding Multimodal Large Language Models to the World

Zhiliang Peng*, Wenhui Wang*, Li Dong*, Yaru Hao, Shaohan Huang, Shuming Ma, Furu Wei†
Microsoft Research
<https://aka.ms/GeneralAI>

Abstract

We introduce KOSMOS-2, a Multimodal Large Language Model (MLLM), enabling new capabilities of perceiving object descriptions (*e.g.*, bounding boxes) and grounding text to the visual world. Specifically, we represent refer expressions as links in Markdown, *i.e.*, “[text span] (bounding boxes)”, where object descriptions are sequences of location tokens. Together with multimodal corpora, we construct large-scale data of grounded image-text pairs (called GRIT) to train the model. In addition to the existing capabilities of MLLMs (*e.g.*, perceiving general modalities, following instructions, and performing in-context learning), KOSMOS-2 integrates the grounding capability into downstream applications. We evaluate KOSMOS-2 on a wide range of tasks, including (i) multimodal grounding, such as referring expression comprehension, and phrase grounding, (ii) multimodal referring, such as referring expression generation, (iii) perception-language tasks, and (iv) language understanding and generation. This work lays out the foundation for the development of Embodiment AI and sheds light on the big convergence of language, multimodal perception, action, and world modeling, which is a key step toward artificial general intelligence. Code and pretrained models are available at <https://aka.ms/kosmos-2>.

Microsoft의 KOSMOS-2

- 공개 정보
 - 2023.07.13. 논문 공개
 - 2023.11.28. 모델 가중치 공개
 - 파라미터 수 1.66B
- GRIT 데이터셋으로 pre-trained
 - LAION-2B, COYO-700M 으로 구성
- 당시 3B이하 모델 중 훌륭한 이미지 캡셔닝 성능
- MIT 라이선스로 수정, 배포, 상업적 이용도 가능

모델 성능 상세

Grounding을 통해 학습한 뛰어난 이미지 캡셔닝 성능

Model	Flickr30k	VQAv2
	CIDEr	VQA acc.
FewVLM [JCS ⁺ 22]	31.0	-
METALM [HSD ⁺ 22]	43.4	41.1
Flamingo-3B [ADL ⁺ 22]	60.6	49.2
Flamingo-9B [ADL ⁺ 22]	61.5	51.8
KOSMOS-1	65.2	46.7
KOSMOS-2	66.7	45.6



01 벤치마크 성능

- 이미지 캡셔닝 벤치마크 Flickr30K
 - Flamingo-9B 보다 성능이 좋다
- 매우 우수한 이미지 캡셔닝 성능

02 Grounding 기능

- 정확히 '어디에 무엇이 있다'를 포착할 수 있다
- 강력한 캡셔닝 성능의 바탕

Flan-T5-Large

작지만 다재다능한 LLM

Scaling Instruction-Finetuned Language Models

Hyung Won Chung* Le Hou* Shayne Longpre* Barret Zoph† Yi Tay†
 William Fedus† Yunxuan Li Xuezhi Wang Mostafa Dehghani Siddhartha Brahma
 Albert Webson Shixiang Shane Gu Zhuyun Dai Mirac Suzgun Xinyun Chen
 Aakanksha Chowdhery Alex Castro-Ros Marie Pellat Kevin Robinson
 Dasha Valter Sharan Narang Gaurav Mishra Adams Yu Vincent Zhao
 Yanping Huang Andrew Dai Hongkun Yu Slav Petrov Ed H. Chi
 Jeff Dean Jacob Devlin Adam Roberts Denny Zhou Quoc V. Le
 Jason Wei*

Google

Abstract

Finetuning language models on a collection of datasets phrased as instructions has been shown to improve model performance and generalization to unseen tasks. In this paper we explore instruction finetuning with a particular focus on (1) scaling the number of tasks, (2) scaling the model size, and (3) finetuning on chain-of-thought data. We find that instruction finetuning with the above aspects dramatically improves performance on a variety of model classes (PaLM, T5, U-PaLM), prompting setups (zero-shot, few-shot, CoT), and evaluation benchmarks (MMLU, BBH, TyDiQA, MGSM, open-ended generation, RealToxicityPrompts). For instance, Flan-PaLM 540B instruction-finetuned on 1.8K tasks outperforms PaLM 540B by a large margin (+9.4% on average). Flan-PaLM 540B achieves state-of-the-art performance on several benchmarks, such as 75.2% on five-shot MMLU. We also publicly release Flan-T5 checkpoints,¹ which achieve strong few-shot performance even compared to much larger models, such as PaLM 62B. Overall, instruction finetuning is a general method for improving the performance and usability of pretrained language models.

Google의 Flan-T5-Large

- 공개 정보
 - 2022.12.6. 논문 공개
 - 2023.1.30. 모델 가중치 공개
 - 파라미터 수 780M
- 473개 데이터셋, 146개 태스크 카테고리, 1836개 태스크를 훈련
- Apache-2.0 라이선스로 수정, 배포, 상업적 이용 가능

모델 성능 상세

기존 T5-Large보다 훨씬 뛰어난 성능

Finetuning tasks

TO-SF

Commonsense reasoning
Question generation
Closed-book QA
Adversarial QA
Extractive QA
Title/context generation
Topic classification
Struct-to-text
...

55 Datasets, 14 Categories, 193 Tasks

Muffin

Natural language inference
Code instruction gen.
Program synthesis
Dialog context generation
...

69 Datasets, 27 Categories, 80 Tasks

Natural Instructions v2

Cause effect classification
Commonsense reasoning
Named entity recognition
Toxic language detection
Question answering
Question generation
Program execution
Text categorization
...

372 Datasets, 108 Categories, 1554 Tasks

CoT (Reasoning)

Arithmetic reasoning
Commonsense Reasoning
Implicit reasoning
...

9 Datasets, 1 Category, 9 Tasks

- ❖ A **Dataset** is an original data source (e.g. SQuAD).
- ❖ A **Task Category** is unique task setup (e.g. the SQuAD dataset is configurable for multiple task categories such as extractive question answering, query generation, and context generation).
- ❖ A **Task** is a unique <dataset, task category> pair, with any number of templates which preserve the task category (e.g. query generation on the SQuAD dataset.)

Held-out tasks

MMLU

Abstract algebra
College medicine
Professional law
Sociology
Philosophy
...

57 tasks

BBH

Boolean expressions
Tracking shuffled objects
Dyck languages
Navigate
Word sorting
...

27 tasks

TyDiQA

Information seeking QA

8 languages

MGSM

Grade school math problems

10 languages

Params	Model	Norm. avg.	MMLU		BBH		TyDiQA	MGSM
			Direct	CoT	Direct	CoT	Direct	CoT
780M	T5-Large	-5.0	25.1	15.0	27.7	16.1	0.0	0.3
	Flan-T5-Large	13.8(+18.8)	45.1	40.5	37.5	31.5	12.3	0.7

01 벤치마크 성능

- MMLU, BBH, TyDiQA, MGSM 등 벤치마크에서 기존 Flan-T5보다 월등한 점수를 기록

02 뛰어난 학습능력

- 방대한 양의 태스크를 학습해 뛰어난 제로샷 성능
- 최종 Multiple Question Answering을 위해 선정

데이터셋 목록

모델을 훈련하기 위해 선정한 데이터셋들

데이터셋	특징	라이선스
A-OKVQA	- 이미지의 내용뿐만 아니라 광범위한 상식 및 세상에 대한 배경지식, 그리고 추론 능력을 요구하는 24,903개 문제들로 구성	Apache-2.0
Visual 7w	- 47,300개의 COCO 이미지와 327,939개의 질문-답변 쌍으로 구성 - 질문이 What, Where, When, Who, Why, How, Which의 7가지 'W'로 시작하도록 체계적으로 구성	MIT
VMC	- 20개의 기존 VQA 데이터셋을 변환하여 만들어진 9,018개 문제 - 기존의 사람이 만든 문제와 비교했을 때 난이도가 비슷하거나 더 어려움	MIT
RealworldQA	- xAI에서 만든 현실 세계 공간 이해 능력을 평가하기 위해 설계된 765개 문제 데이터셋 - 난이도가 높아 최신 AI 모델들도 60% 이상의 정확도를 넘어서기 어려움	CC BY-ND 4.0.
Stanford	- 단일 문장으로 이미지를 설명하기보단 각 문장이 더 다양하고 풍부하며 , 여러 문장이 서로 연결되어 일관성 있는 스토리를 전달	CC0: Public Domain
Recap-COCO-30K	- 기존의 COCO 데이터셋을 LLaVA 1.5로 다시 캡셔닝하여 개선 - 원본보다 어휘가 훨씬 풍부하고 문장이 평균 5배 정도 길어짐	CC-BY-4.0
대회 데이터	- 단순한 시각적 정보 파악을 넘어 시각적 식별, 상식과 배경지식, 목적 및 의도 추론 등 다양한 종류의 능력을 요구 - 김밥 등 한국 문화 특화된 지식도 요구	SCPC 대회 규정을 따름

데이터셋 증강

로컬 모델을 통해 데이터셋에 훈련용 이미지 캡셔닝을 추가



The image captures a vibrant beach scene under a clear blue sky. The sandy beach is dotted with numerous people engaged in various activities. Some are walking along the shore, while others are playing volleyball. A few individuals are sitting or lying on towels, soaking up the sun. In the foreground, a group of people is building sandcastles, adding to the lively atmosphere. Palm trees line the right side of the beach, providing shade and enhancing the tropical ambiance. The calm sea stretches out to the horizon, with a few boats visible in the distance. The overall mood is one of relaxation and enjoyment, typical of a sunny day at the beach.

로컬 모델을 통해 이미지 캡셔닝을 추가

- LiAutoAD/Ristretto-3B 모델 사용
 - 3B 급 모델 중 뛰어난 이미지 캡셔닝 성능
 - Qwen2.5-VL-3B, InternVL2.5-4B 상회
- 이미지 캡셔닝이 없던 데이터셋을 증강
 - Visual 7w
 - VMC
 - Realworld QA
 - 대회 데이터

KOSMOS-2 훈련

품질 좋은 이미지 캡셔닝을 생성하게끔 두 페이지로 나눠 훈련

1 페이지

- Weighted Random Sampler 사용
 - 각기 다른 사이즈의 데이터셋을 하나로 concat 했을 때, 각 샘플이 균일한 확률로 샘플링 될 수 있게 확률 가중치 조정
- 상대적으로 간단한 이미지 캡셔닝을 지닌 데이터셋으로 구성
 - 증강된 RealworldQA, VMC, 대회 데이터
 - 문장이 짧은 A-OKVQA, Stanford

2 페이지

- Recap-COCO-30K로 구성
 - 가장 캡셔닝 문장 품질이 좋고 사이즈가 30K로 큼
- 두 페이지 모두 VLM의 이미지 캡셔닝 능력만 훈련

Flan-T5-Large 훈련

데이터셋 난이도에 따른 커리큘럼 러닝 구성

커리큘럼 러닝

- 질문 난이도와 그에 요구되는 능력을 고려하여 커리큘럼 러닝 순서 구성
- 순서는 쉽거나 외부 지식을 덜 이용하는 것부터 배치
 - Visual 7w
 - Realworld QA
 - A-OKVQA
 - VMC

인스트럭션 튜닝

- 프롬프트 구성
 - 이미지 캡션, 질문, 선택지를 읽고 답을 선택하게끔 훈련
- 프롬프트를 다양화 하기보다는 싱글 프롬프트에 대해 성능이 맞춰지도록 훈련

최적화 기법

훈련 및 추론 속도, 메모리 사용량을 최적화 하기위한 기법이 필요

01

RTX 3090 GPU(VRAM 24GB), RAM 64GB의 제한된 리소스 환경



02

제한된 환경에서 최대한 실험을 빠르고 많이 하기위해 최적화 기법이 필요



03

양자화, LoRA, 컴파일러 기반 최적화, 커널 퓨전 기술을 사용해 구현

QLoRA 적용

KOSMOS-2에 QLoRA(Quantization + LoRA)를 적용하여 훈련 경량화, 효율화

Q

- Quantization(양자화)를 위해 "BitsAndBytes" 라이브러리 사용
- NF4 데이터 타입을 이용하여 4-bit로 가중치 양자화
 - 메모리 사용량 75% 감소 효과
 - 16-bit(float16)과 거의 유사한 성능

LoRA

- LoRA(Low-Rank Adaption) 적용
 - 비전 모델은 freeze
 - 언어 모델의 어텐션, 피드포워드 네트워크와 Image to Text projection 레이어에 적용
- 임베딩 레이어와 언어 모델 최종 출력 레이어는 LoRA를 적용하지 않고 학습
- 전체 파라미터 갯수 중 **14.75%**만 효율적으로 훈련

속도 및 메모리 최적화

최적화 기술 사용으로 연산 속도와 메모리 사용량을 개선

Flash Attention

- 기존 어텐션 연산에 특화된 가속화 기술
- 트랜스포머는 어텐션 연산 속도가 가장 큰 병목
- 효과
 - HBM이 아닌 SRAM에서 어텐션 스코어 계산을 하여 메모리 사용량 개선
 - HBM 접근 횟수를 줄여 기존 알고리즘에 비해 연산 속도 2배 이상 개선

torch.compile

- 모델을 최적화된 C++ 혹은 CUDA 코드로 하나의 연산 그래프로 변환
- 기존 모델 연산시 CPU, GPU 통신의 오버헤드가 발생
- 효과
 - GPU, CPU간의 오버헤드 제거
 - 중간 결과 저장에 SRAM을 활용하여 메모리 사용량 개선

중간 성능 지표

훈련 동안 모델의 성능 변화를 측정할 수 있는 좋은 지표가 필요

Q1

어떻게 이미지 캡셔닝 문장의 품질을 평가할 것인가?

Q2


어떻게 정답 선택지를 맞췄는지 정확하게 판별할 것인가?

!

각 모델의 훈련 목적에 맞는 평가 척도가 필요

METEOR

METEOR 스코어로 KOSMOS-2 이미지 캡셔닝 성능을 평가




1, 2 에포크는 1 페이지 훈련, 3, 4 에포크는 2 페이지 훈련

METEOR - 문장 유사도 평가 척도


- 유의어 매칭 허용
 - run - running , car - automobile은 유의어이므로 동일 단어 취급
- 문장 내 단어 순서가 일치하는지 평가
 - 단어 순서가 일치하는 가장 긴 문장들을 찾고 문장 내 단어 갯수에 따라 페널티 부과
- 정밀도와 재현율의 조화 평균으로 평가
 - 두 척도 간의 균형이 맞아야 높게 평가
 - 하나라도 낮으면 낮은 점수 기록

최종 정답율

Flan-T5-Large가 최종 답을 얼마나 맞췄는지 평가



커리큘럼 러닝 동안의 validation 정답율



Train.csv 정답율

최종 정답율

- Flan-T5-Large 모델의 응답에서 최종 선택지를 추출하여 정답 여부를 판별
- 표준정규식(Regular Expression) 사용
 - 모델의 응답에서 정확하게 최종 선택을 검색하여 추출
- 최종 정답율 산출식은 "정답 갯수 ÷ 전체 갯수"

결과물 확인

파라미터 수 제한과 최종 점수 확인

	팀	팀 멤버	최종 점수
PRIVATE	Ricepunchb		0.73794
PUBLIC	Ricepunchb		0.74551

01 최종 파라미터 수

- KOSMOS-2 파라미터 수: 1.95B
- Flan-T5-Large 파라미터 수: 0.78B
- **전체 파라미터 수: 2.74B**

02 리더보드 점수

- Public 리더보드 점수: 0.74551
- Private 리더보드 점수: 0.73794

아쉬웠던 점

제한점 및 차후 개선 방향

01

제한된 리소스로 인해 모델 훈련을 여러번 해보지못했음 (훈련 1회 약 11시간)
- 분산 GPU 환경이었다면 더 많은 실험과 훈련을 할 수 있었을 것 같다

02

한국 문화권 특화 이미지-텍스트 데이터를 찾기 힘들었음
- 해외의 여러 유명 데이터셋을 확보했으나 정작 한국 문화권의 데이터가 극도로 적었다

03

DPO, RLHF 같은 강화학습 기법으로 최종 튜닝을 했다면 더 좋았을 것
- 강화학습 하기위한 데이터셋 추가 전처리, 하이퍼 파라미터 서치를 할 시간이 부족했음

감사합니다

자유로이 질문해주세요!

